Флоренская Лидия

Data Scientist



Контакты

Москва, Россия
florenskaia.lk@phystech.edu
+7 916 804 84 43
github.com/florenskaial118
t.me/lidaf118

Технические навыки

Языки и БД: Python (pandas, numpy, scikit-learn, CatBoost, базовый PyTorch), SQL (PostgreSQL, ClickHouse), R

Проверка моделей: кросс-валидация, ROC-AUC, precision/recall, подбор порога

Инженерия: Airflow, Spark, Hadoop, Docker, Git, Linux (bash-скрипты)

Языки

Русский (родной)
Английский (B2)

Студентка 6-го курса МФТИ, по образованию биоинформатик.
Специализируюсь на анализе данных и ML-пайплайнах.
Меня привлекают прикладные задачи, где за цифрами стоит реальный мир

Образование

МФТИ (Физтех). Прикладная математика и физика 2021–2027

Физтех-школа биологической и медицинской физики (бакалавриат) 2021–2025
Физтех-школа биологической инженерии (магистратура) 2025–2027

Диплом о профессиональной переподготовке МФТИ — «Продвинутые методы машинного обучения» 2024

Опыт работы

Лаборант-исследователь (ИОГЕН РАН) сентябрь 2024 — июнь 2025

Статистический анализ биологических датасетов: от сырых данных до проверки гипотез и публикации результатов.

- Автоматизация: Python/Bash-скрипты для очистки, агрегации данных и генерации сводных отчетов на сервере.
- Статистический анализ: тесты Фишера, Манна-Уитни с FDR-коррекцией, TMM, NMDS, Шеннон/Брей-Кертис; из 600 генов патогенности успешно выделено 59 статистически значимых.
- Коммуникация: подготовка отчетов, публичная защита результатов и публикация в материалах IV Российского конгресса по медицинской микробиологии.

Пет-проекты

Кому звонить — ML-пайплайн для оптимизации прибыли банковской кампании

Репозиторий: github.com/florenskaial118/bank-deposit-profit-ml

- End-to-end ML-пайплайн: Airflow DAG (RAW $\rightarrow$ ODS $\rightarrow$ Mart $\rightarrow$ Train), логистическая регрессия и Random Forest (5 folds). Оптимизация под бизнес-метрику ($10 депозит / $2 звонок).
- Бизнес-эффект: Кастомный подбор порога поднял среднюю прибыль на OOF-фолде с $1502 ($\pm 183$) до $2786 ($\pm 116$) — **рост в 1.9 раза** по сравнению с бейзлайном.

ETL-пайплайн для анализа пользовательской активности

Репозиторий: github.com/florenskaial118/JSONPlaceholder-ETL

- Архитектура данных: 3-хуровневая архитектура (RAW/ODS/Mart) с партиционированием в HDFS, парсинг JSON через Apache Spark.
- Оркестрация и хранение: Оркестрация в Airflow, хранение в ClickHouse, контейнеризация в Docker.

Достижения и навыки

- **Управление проектами:** победитель грантовых конкурсов МФТИ («Физтех.спорт»).
- **Публичные выступления:** доклады на 67-й конференции МФТИ (секция биоинформатики) и публикации на профильных конгрессах (РКММИ 2026, стр. 436 и РКММИ 2025, стр. 360).
- Аккуратна при работе с цифрами; быстрая обучаемость; тайм-менеджмент.